

동의대학교 인공지능학과

자연어처리의 개요

Ph.D 김정순 | 원더솔루션즈 AI연구개발부 연구소장



Presentation Index

01

자연어처리의 발전 과정

- Rule-based
- Statistical
- Deep Learning

02

자연어처리의 주요 Task

- Classification
- Generation
- Understanding

03

텍스트 임베딩 기법의 진화

- BoW(Bag-of-Word)
- TF-IDF
- Word2Vec
- Cross-lingual
- Hybrid Embedding
- Multimodel Embedding

04

딥러닝 기반 언어모델과 최신모델

- CNN, LSTM
- Transformer
- BERT & GPT
- LLM(LLaMA, GPT-3, GPT-4 등)
- RLHF(인간 피드백기반 강화학습)

01



자연어처리의 발전과정

자연어처리(NLP)란 무엇인가?

- 자연어처리(NLP)는 인간이 일상적으로 사용하는 언어를 컴퓨터가 이해하고 처리할 수 있게 하는 인공지능의 한 분야
- 텍스트, 음성 데이터를 분석하고 의미를 파악하는 기술 전반 포함

왜 중요한가?

- 스마트폰 음성비서, 번역 앱, 챗봇 등 일상의 AI 서비스 대부분이 NLP 기반
- 검색엔진, SNS 감성 분석, 문서 자동 요약 등 기업 활용도 매우 높음

핵심과제-언어는 왜 어려운가?

- 중의성: '배'는 과일? 신체? 교통수단?
- 문맥 의존성: 같은 문장도 앞뒤 맥락에 따라 의미가 달라짐
- 다양성: 언어마다 문법, 어순, 형태소 구조가 완전히 다름

규칙기반(Rule-based)

개요

- 사람이 직접 언어 규칙·사전을 컴퓨터에 입력
- if-then 형태의 명시적 규칙 코딩

장점

- 좁은 도메인에서 매우 정확
- 결과를 예측·설명하기 쉬움

한계

- 예외 상황을 규칙으로 정의 불가
- 언어의 미묘한 뉘앙스 처리 어려움
- 확장 불가 → 다른 언어, 다른 주제엔 처음부터 재작성



통계기반(Statistical)

개요

- 규칙 대신 '확률'기반-대량의 데이터에서 패턴을 학습
- "이 단어 다음에 어떤 단어가 올 확률이 가장 높은가?"를 계산

장점

- 이전 N-1개의 단어를 보고 다음 단어 예측
- Copus(말뭉치) 크기가 성능 결정

한계

- 데이터 희소성 문제: 학습 데이터에 없는 조합은 확률 0
- 단어의 '의미'는 학습 불가
- 긴 문장에서 앞의 문맥을 유지하기 어려움



딥러닝(Deep Learning)

개요

- 사람이 특징(feature)을 설계할 필요 없이 모델이 스스로 특징 학습
- 단어를 의미 있는 벡터(숫자)로 표현 – Word Embedding
- 순서가 있는 텍스트를 처리하는 RNN, LSTM 등장
- 2012년 ImageNet에서 딥러닝 모델 압승을 거두면서 NLP 연구분야 가속화 됨

장점

- 기계번역, 요약 등 생성 가능
- 현재 ChatGPT, GPT-3 등 초거대 언어 모델(LLM)의 토대



02



자연어처리의 주요 Task

NLP가 실제로 해결하는 현실세계의 문제들

분류(Classification)

- 감성분석: 리뷰 긍정/부정
- 스팸 필터링
- 주제 분류(뉴스 카테고리)
- BERT, RoBERTa

생성(Generation)

- 기계번역: 한국어 ↔ 영어
- 문서 요약
- 챗봇 · 가상비서
- 창작: 소설 · 코드 작성

이해(Understanding)

개요

- 질의응답(QA): 독해 기반
- 개체명 인식(NER)
- 관계 추출

LLM은 모두 통합 처리 가능

왜 전처리(Pre-Processing)가 필요한가?

- 컴퓨터는 문자를 직접 이해하지 못함 → 숫자(벡터)로 변환 필요
- 전처리: 소문자화, 특수문자 제거, 불용어(stopwords) 제거 등

토큰화(Tokenization)란?

- 문장을 의미 있는 최소 단위(토큰)로 쪼개는 작업
- 단어 단위: '나는 밥을 먹었다' → ['나는', '밥을', '먹었다']
- 서브워드 단위: 'unhappiness' → ['un', '##happi', '##ness'] (BERT 방식)

최신 트렌드: SubWord Tokenization

- BPE(Byte Pair Encoding), WordPiece 등
- 미등록어(OOV) 문제 해결 — 처음 보는 단어도 처리 가능
- GPT, BERT 등 현대 대형 모델이 모두 사용

영어와 다른 한국어의 특성

- 교착어: 조사·어미 등 형태소가 단어에 붙어 의미를 결정
- '먹었다', '먹었니', '먹었는데' — 어근은 같지만 의미 다양
- 공백만으로는 단어 경계 파악 불충분

형태소 분석의 중요성

- 형태소: 의미를 가지는 최소 단위
- '학교에서' → '학교(명사)' + '에서(조사)'로 분리해야 정확한 처리 가능
- 대표 모델: KoNLPy (Okt, Mecab, Komoran 등)

한국어 NLP의 과제

- 신조어·은어: '갑분싸', '맞팔', '핵인싸' 등 빠른 신어 생성
- 같은 발음, 다른 의미: '눈(eye)'과 '눈(snow)'
- BERT/GPT 기반 한국어 모델: KoBERT, HyperCLOVA 등 개발 활발

03



텍스트 임베딩 기법의 진화


단어를 숫자 벡터로 표현하는 방법

Text Embedding이란?

- 컴퓨터는 글자를 그대로 이해하지 못함 → 모든 텍스트를 '숫자(Vector)'로 변환해야 함
- 벡터 공간에서 유사한 의미의 단어는 가까운 위치에 표현

왜 임베딩이 중요한가?

- '강아지'와 '개'는 다른 단어이지만 의미적으로 매우 유사
- 좋은 임베딩이란? 의미적 유사도가 벡터 공간에 올바르게 반영된 상태
- 모든 NLP 모델의 입력 단계-임베딩 품질이 전체 성능을 좌우함



현대 NLP 모델의 학습 메커니즘

= 문맥 기반 Embedding+문장 간 비교+벡터공간의 거리+정렬(Alignment)

과거의 AI가 단어장에 적힌 뜻만 외우는 학생이었다면, 신경망 이후의 AI는 두 문장을 나란히 놓고(Comparison) 얼마나 비슷(Similarity)한지 느끼며 서로 다른 언어나 이미지를 하나로 연결(Alignment)하는 수준에 도달하였습니다.

전통 통계 방법 Embedding

- One-hot encoding
- Bag-of-Words
- TF-IDF(Term Frequency, Inverse Document Frequency): 특정 문서에만 자주 등장하는 단어에 높은 점수

- 단어의 빈도수만 카운트
- 전체 어휘 크기만큼의 벡터 생성
- 각 단어가 등장한 횟수를 해당 위치에 기록 → 희소 벡터(sparse vector)로 표현



신경망 기반 워드 Embedding

- Word2Vec: 단순 빈도 → '의미와의 관계'를 공간상의 벡터로 표현
- GloVe(Global Vectors for Word Representation): 데이터 전체의 통계를 반영한 모델
- FastText: 단어를 더 쪼갬 N-gram 단위 접근, 서브워드 단위 학습

- 주변 단어들로 중심 단어 예측
- '왕 - 남자 + 여자 ≈ 여왕' — 단어 간 수학적 연산 가능



문맥 기반 Embedding

- ELMo(Embedding from Language Models): 양방향 LSTM으로 문맥 반영
- BERT: Transformer 기반, 입력 → 출력 시퀀스 생성
- GPT : Token, Position Embedding


- 단어 고유의 벡터 하나만 사용하는 것이 아닌 주변 단어들과의 관계를 실시간으로 벡터 값 생성
- 딥러닝 기반의 특징 자동 학습
- 고차원 벡터로 표현하여 컴퓨터가 계산할 수 있도록 함

04



딥러닝 기반과 최신 언어 모델까지

Transformer→GPT-4 →GPU Infra



LLM의 시대: GPT-3, GPT-4, 현재 진행 중

ChatGPT의 놀라운 성능은 Transformer라는 혁신적인 설계도와 GPU라는 강력한 엔진이 만난 결과물

딥러닝 기반 언어 모델(MLP, CNN)의 개요

- MLP: 가장 기초적인 신경망으로 텍스트 분류의 기반이 됨
- Word2Vec: MLP 구조를 활용해 단어를 의미 있는 벡터로 변환하는 임베딩 학습 모델
- CNN: 이미지 처리 방식을 응용해 문장 내 패턴을 탐색함.
- 텍스트 분류: 스팸 메일 차단, 단순 감정 분석
- 특징 탐색: 문장 내 특정 키워드 패턴 포착 및 문장 분류 고도화

시계열 데이터의 정복(RNN, LSTM)

- 텍스트의 '순서'와 '문맥'을 본격적으로 처리하기 시작한 단계
- RNN, LSTM: 순서가 있는 텍스트 처리에 특화된 신경망 모델
- Seq2Seq: 입력 시퀀스를 받아 출력 시퀀스를 생성하는 구조
- 초기 BERT, GPT: 문맥을 이해하기 위한 초기 형태의 신경망 모델
- 수행 Task: 기계 번역, 언어 모델링, 문서 요약

기존 딥러닝 기반 언어 모델의 문제점

- 단어를 '순차적'으로 처리 → 긴 문장일수록 앞 정보 소실
- 병렬 처리 불가 → 학습 속도 느림

Transformer의 혁신(2017, Vaswani et al.)


- 모든 단어를 '동시에 병렬'로 처리 → 속도·성능 대폭 향상
- Self-Attention: 문장 내 모든 단어 쌍의 관계를 한 번에 계산
- RNN 구조 완전 제거 → 'Attention Is All You Need'

핵심 구성

- 크게 Encoder와 Decoder로 구성
- Multi-Head Attention: 여러 관점에서 동시에 Attention 계산
- Position Encoding: 순서 정보를 sin/cos 함수로 벡터에 추가
- Layer Norm + Residual Connection: 깊은 네트워크 학습 안정화

수행 Task

- 기계번역, 문맥 의존적 임베딩 추출, 질의응답 및 기계 독해, 문서 요약, 문장 분류 및 감정 분석 등



BERT

- MLP: 텍스트 분류
- 단어 임베딩 학습: Word2Vec
- CNN: 문장 내 특정 키워드 패턴 탐색, 문장 분류 고도화



GPT

- RNN, LSTM, BERT, GPT
- Seq2Seq 구조를 통해 기계번역
- 언어 모델링: 이전 단어들을 바탕으로 다음 단어 예측
- 문서 요약



Transformer 기반

- "Attention is All You Need" 논문 발표
- 순차처리를 버리고 병렬 처리 가능
- 임베딩의 고도화

- 왜 GPU가 필요한가?

- Transformer의 핵심 = 대규모 행렬 곱 연산
- CPU: 소수의 강력한 코어 → 순차 처리 강점
- GPU: 수천 개의 작은 코어 → 행렬 병렬 처리에 최적화

- 학습 비용 현실

- Google T5 (2019): TPU Pod v3 → 약 2주 / ~30억원
- GPT-3 (2020): TPU Pod v3 → 약 4주 / ~60억원
- GPT-4 추정: 수천억 원 이상

- AI 경쟁 = GPU 확보 전쟁

- NVIDIA A100/H100 GPU 수요 폭발 → 공급 부족
- Microsoft(OpenAI에 투자), Google(TPU 자체 개발), Amazon(AWS Trainium)
- 한국도 NAVER, SK, KT 등 대규모 인프라 투자 중

GPU

4장

A100 GPU 최소 필요량

- 80GB VRAM
- 326GB 모델

하드웨어 비용

6천만원

A100 4장 * 1,500만원

동시 1만명 서비스

월 334억

전력+장소+하드웨어 포함
연간 약 4,000억원

- **GPT-3.5 대비 향상점**
 - 훨씬 넓은 일반 지식 + 강화된 문제 해결·추론 능력
 - 더 긴 **Context Window**: 3,000단어 → 25,000단어 이상(약 50페이지) 한 번에 처리
 - 안전장치 강화: 허위 정보 감소, 일관성 있는 답변
- **Vision — 눈을 뜬 AI**
 - 텍스트 + 이미지 동시 입력 가능 (멀티모달)
 - 재료 사진 → 만들 수 있는 요리 추천
 - 물리 문제 손글씨 사진 → 풀이 제공
- **뛰어난 전문성 & 다국어 지원**
 - 미국 변호사 시험(Uniform Bar Exam) 상위 10% 성적
 - 한국어 포함 비영어권 언어 이해도 비약적 향상
 - GPT-3 대비 한국어 정확도 눈에 띄게 개선



Thank you!

- 김정순 -

Email : js.kim@deu.ac.kr