

동의대학교 인공지능학과

Word2Vec

Ph.D 김정순 | 원더솔루션즈 AI연구개발부 연구소장

CBOW

Skip-gram

Negative Sampling

Subsampling

Word Embedding

Gensim 실습

Presentation

Index

01

Word2Vec 개요

- CBOW & Skip-gram 구조
- One-hot Encoding 한계
- Word Embedding 개념

03

학습 최적화 기법

- 네거티브 샘플링 (Negative Sampling)
- 학습전략 1: 희귀 단어 샘플링
- 학습전략 2: 서브샘플링

02

Skip-gram 상세

- Window Size 학습 데이터 생성
- 신경망 구조 (Input→Hidden→Output)
- 임베딩 벡터 추출 원리

04

Gensim 실습

- 형태소 말뭉치 준비
- Word2Vec 학습 코드
- 최 근접 벡터 검색

01



Word2Vec 개요



■ CBOW (Continuous Bag-of-Words)


주변에 있는 문맥 단어들을 가지고 타깃 단어를 예측하는 모델

■ Skip-gram

타깃 단어를 가지고 주변 문맥 단어를 예측하는 모델


© Skip-gram이 같은 말뭉치로도 더 많은 학습이 가능





One-hot encoding

unique word	encoding
thank	[1, 0, 0]
you	[0, 1, 0]
love	[0, 0, 1]



문제점: 모든 단어 쌍의 내적 = 0

코사인 유사도(cosine similarity)가 항상 0

→ 어떤 두 단어도 '가깝다'/'멀다'를 표현할 수 없음

→ 'king'과 'queen'이 'apple'보다 가깝다는 정보 없음

Word2Vec Embedding

unique word	encoding	embedding
king	[1, 0, 0, 0]	[1, 2]
man	[0, 1, 0, 0]	[1, 3]
queen	[0, 0, 1, 0]	[5, 1]
woman	[0, 0, 0, 1]	[5, 3]

02



Skip-gram 상세

(window size = 1)

"king brave man"

"queen beautiful woman"

Window Size란?

중심 단어(center word)를 기준으로
좌우 몇 개의 단어를 '주변 단어'로
볼 것인지 결정하는 하이퍼파라미터

window=1 → 바로 옆 단어만


window=2 → 2칸 이내 단어

word	neighbor
king	brave
brave	king
brave	man
man	brave
queen	beautiful
beautiful	queen
beautiful	woman
woman	beautiful

Word2Vec data generation (window size = 2)


word	word one hot encoding	neighbor	neighbor one hot encoding
king	[1,0,0,0,0,0]	brave	[0,1,0,0,0,0]
king	[1,0,0,0,0,0]	man	[0,0,1,0,0,0]
brave	[0,1,0,0,0,0]	king	[1,0,0,0,0,0]
brave	[0,1,0,0,0,0]	man	[0,0,1,0,0,0]
man	[0,0,1,0,0,0]	king	[1,0,0,0,0,0]
man	[0,0,1,0,0,0]	brave	[0,1,0,0,0,0]
queen	[0,0,0,1,0,0]	beautiful	[0,0,0,0,1,0]
queen	[0,0,0,1,0,0]	woman	[0,0,0,0,0,1]

: (계속)



학습 과정

- ① king의 one-hot 벡터 입력
- ② W_1 행렬과 곱 → 임베딩 추출
- ③ W_2 행렬 → 출력 스코어
- ④ Softmax → 확률 분포
- ⑤ 정답(brave)과 비교
- ⑥ Cross-Entropy Loss 계산
- ⑦ 역전파 → W_1, W_2 업데이트



최종 임베딩 테이블 (Hidden Layer 가중치 = W_1)

unique word	embedding
king	[1, 1]
brave	[1, 2]
man	[1, 3]
queen	[5, 5]
beautiful	[5, 6]
woman	[5, 7]

핵심 포인트

학습 완료 후, Hidden Layer의 가중치 행렬 W_1 자체가 단어 임베딩 룩업 테이블(Embedding Table)이 됩니다!

03



학습최적화 기법

■ 네거티브 샘플링

해당 쌍이 포지티브 샘플인지, 네거티브 샘플인지 이진 분류(Binary Classification)를 학습

◎ 논문에서는 네거티브 샘플의 경우 작은 데이터에서는 5~20개, 큰 데이터에서는 2~5개로 학습하는 것을 추천

... 개울가 (에서 속옷 빨래 를 하는) 남녀 ...

c_1

c_2

t

c_3

c_4

포지티브 샘플

t	c
빨래	에서
빨래	속옷
빨래	를
빨래	하는

네거티브 샘플

t	c
빨래	책상
빨래	안녕
빨래	자동차
빨래	숫자

t	c
빨래	커피
빨래	떡
빨래	사과
빨래	노트북

그림 4-9 Skip-gram 모델의 학습 데이터 구축

cat → Skip-gram → sat

↓ Negative Sampling 적용

cat + sat → Skip-gram (Negative Sampling) → 0.88

The fat cat sat on the mat

중심 단어: cat, 주변 단어: 화살표

입력과 레이블의 변화 (Before)

입력	레이블
cat	The
cat	fat
cat	sat
cat	on
sat	fat



레이블 추가 (After)

입력1	입력2	레이블
cat	The	1
cat	fat	1
cat	sat	1
cat	on	1
sat	fat	1
sat	cat	1
sat	on	1
sat	the	1

입력과 레이블의 변화

입력1	입력2	레이블
cat	The	1
cat	fat	1
cat	sat	1
cat	on	1



Negative Sampling 적용


입력1	입력2	레이블
cat	The	1
cat	fat	1
cat	pizza	0
cat	computer	0
cat	sat	1
cat	on	1

↑ 단어 집합에서 랜덤으로 선택된 단어들을 레이블 0의 샘플로 추가


Embedding layer (U)



Embedding layer (V)



cat



← The

= 0.55

← 1

.



← fat

= 0.88

← 1

.




← pizza

= 0.45


← 0

.

Embedding layer



Embedding layer



The

fat

pizza

Error

임베딩 벡터 업데이트!

■ 학습전략 1

희귀한 단어가 잘 뽑히도록 네거티브 샘플링에서는 확률을 조정함 (단순 빈도 비례가 아닌 3/4 제곱 적용)

$$P_{\text{negative}}(w_i) = \frac{U(w_i)^{(3/4)}}{\sum_j U(w_j)^{(3/4)}}$$

$$P(\text{용}) = 0.99^{0.75} / (0.99^{0.75} + 0.01^{0.75}) = 0.97$$

$$P(\text{미른}) = 0.01^{0.75} / (0.99^{0.75} + 0.01^{0.75}) = 0.03$$

🔍 핵심 아이디어

3/4 제곱을 적용하면 희귀 단어의 확률이 상대적으로 올라가고, 고빈도 단어의 확률은 낮아져 더 균형 잡힌 학습이 가능합니다.

 $U (|V| \times d)$

그림 4-10 Skip-gram 모델 파라미터

 $V (d \times |V|)$

■ 학습전략 2

서브샘플링 수행하여 모두 학습시키는 것이 비효율적인 고빈도 단어의 학습 횟수를 확률적으로 조정

◎ t 는 하이퍼파라미터로 10^{-5} 를 추천

◎ $f(w)$ 가 0.01로 나타나는 고빈도 단어일 때 계산식에서는 0.9684로,
100번 학습 기회 가운데 96번을 제외

$$P_{\text{subsampling}}(w_i) = 1 - \sqrt{t / f(w_i)}$$

매개변수 설명

$f(w_i)$: 전체 단어 중 해당 단어의 등장 비율
 t : 하이퍼파라미터 (권장값 = 10^{-5})
 P 값이 클수록 더 많이 제외됨

계산 예시 ($f(w) = 0.01$)

$$\begin{aligned} P &= 1 - \sqrt{10^{-5} / 0.01} \\ &= 1 - \sqrt{0.001} \\ &= 1 - 0.0316 \approx 0.9684 \\ &\rightarrow 100\text{번 중 약 } 96\text{번 제외!} \end{aligned}$$

04



Gensim 실습

■ 형태소 분석 말뭉치 다운로드

```
git pull origin master  
bash preprocess.sh dump-tokenized
```

■ 말뭉치 병합

```
cd /notebooks/embedding  
cat data/tokenized/wiki_ko_mecab.txt data/tokenized/ratings_mecab.txt  
data/tokenized/korquad_mecab.txt > data/tokenized/corpus_mecab.txt
```

말뭉치 종류

wiki_ko_mecab.txt (위키백과) + ratings_mecab.txt (영화 리뷰) + korquad_mecab.txt (KorQuAD) → 통합 말뭉치

■ 젠심(Gensim) 학습 코드

```
corpus_fname = "/notebooks/embedding/data/tokenized/korquad_mecab.txt"
model_fname = "/content/embedding/word2vec"

from gensim.models import Word2Vec
corpus = [sent.strip().split(" ") for sent in open(corpus_fname, 'r').readlines()]
model = Word2Vec(corpus, workers=4, sg=1) # sg=1: Skip-gram
model.wv.save_word2vec_format(model_fname)
```

■ 최 근접 벡터 검색

```
from gensim.models import keyvectors

loaded_model = keyvectors.load_word2vec_format("/content/embedding/word2vec")
model_result = loaded_model.most_similar("남자")
print(model_result) # → [('소년', 0.85), ('여자', 0.81), ('청년', 0.79) ...]
```



Thank you!

- 김정순 -

Email : js.kim@deu.ac.kr